Теоретическая информатика. Домашка 8. Анти-галлюцинатор III: Последняя кровь

Екатерина Шеметова (katyacyfra@gmail.com)

23.10.2026

Мягкий дедлайн: 06.11.2026 23:59
Жесткий дедлайн: 13.11.2026 23:59
Количество баллов на зачет: 14
Пришла пора проверить, насколько успешно LLM генерят **регулярные выражения**.

1 Проверка формата регулярного выражения, 7 баллов

Для каждого из четырех тесткейсов из прошлой домашки попросите LLM написать регулярное выражение (20-50 запросов), модели лучше брать те же, что и в задании с автоматами.

Регулярные выражения задаются индуктивно следующим образом (α, β — регулярные выражения):

- Символы алфавита
- Конкатенация $\alpha\beta$
- Альтернатива $\alpha \mid \beta$
- Клини α^*

У операций есть приоритет, поэтому **необходимо также добавить скобки**!
Примеры валидных регулярных выражений:

- `0`*`1`
- `(0|1|2)2`*
- `(a|bb)`$^*a$

Для решения задачи используйте парсер-генератор ANTLR4 (https://www.antlr.org/). Нужно будет задать грамматику корректных регулярных выражений в g4-файле, сгенерить по ней парсер, лексер, а также классы-заготовки, реализующие шаблоны проектирования Посетитель (Visitor) и Наблюдатель (Listener).

Добавьте метод-проверку корректности (соответствия формату (грамматике)) сгенеренной регулярки с помощью ANTLR.

2 Алгоритм Томпсона и корректность, 7 баллов

Реализуйте алгоритм Томпсона, который переводит регулярку в конечный автомат.

- ANTLR будет строить деревья разбора для сгенеренной регулярки
- Используйте алгоритм Томпсона, чтобы обходя дерево разбора, получать части автомата
- Полученный автомат проверьте на эквивалентность с ground truth автоматом

В итоге должна получится следующая табличка (как всегда, жду глубокомысленных выводов по ней)

	Средняя длина регулярки			Корректные по формату, %			Корректные, %		
	GPT	GigaChat	...	GPT	...	...	GPT		
basic									
4th-symbol									
...									
Итого									

В КОНЦЕ СРАВНИТЕ РЕЗУЛЬТАТЫ ПО ГЕНЕРАЦИИ АВТОМАТОВ И РЕГУЛЯРОК! Что получается лучше и почему?

НЕ ЗАБЫВАЕМ ПОКРЫВАТЬ КОД ТЕСТАМИ!